Основы системного программирования

Ввод-вывод и работа с файлами. Многозадачность и процессы. Трассировка программ

Гирик Алексей Валерьевич

Университет ИТМО
2021

Материалы курса

- Презентации, материалы к лекциям, литература, задания на лабораторные работы
  - shorturl.at/gjABL

Ввод-вывод и работа с файлами

Подсистема ввода-вывода

- любой POSIX-совместимой системе присущи отличительные особенности:
  - модель ввода-вывода на основе файлов
    - представление устройств и системных объектов в виде файлов
    - ограниченный набор универсальных файловых операций
  - единое дерево каталогов с точками монтирования, куда подключаются различные файловые и псевдофайловые системы
    - в Linux - VFS

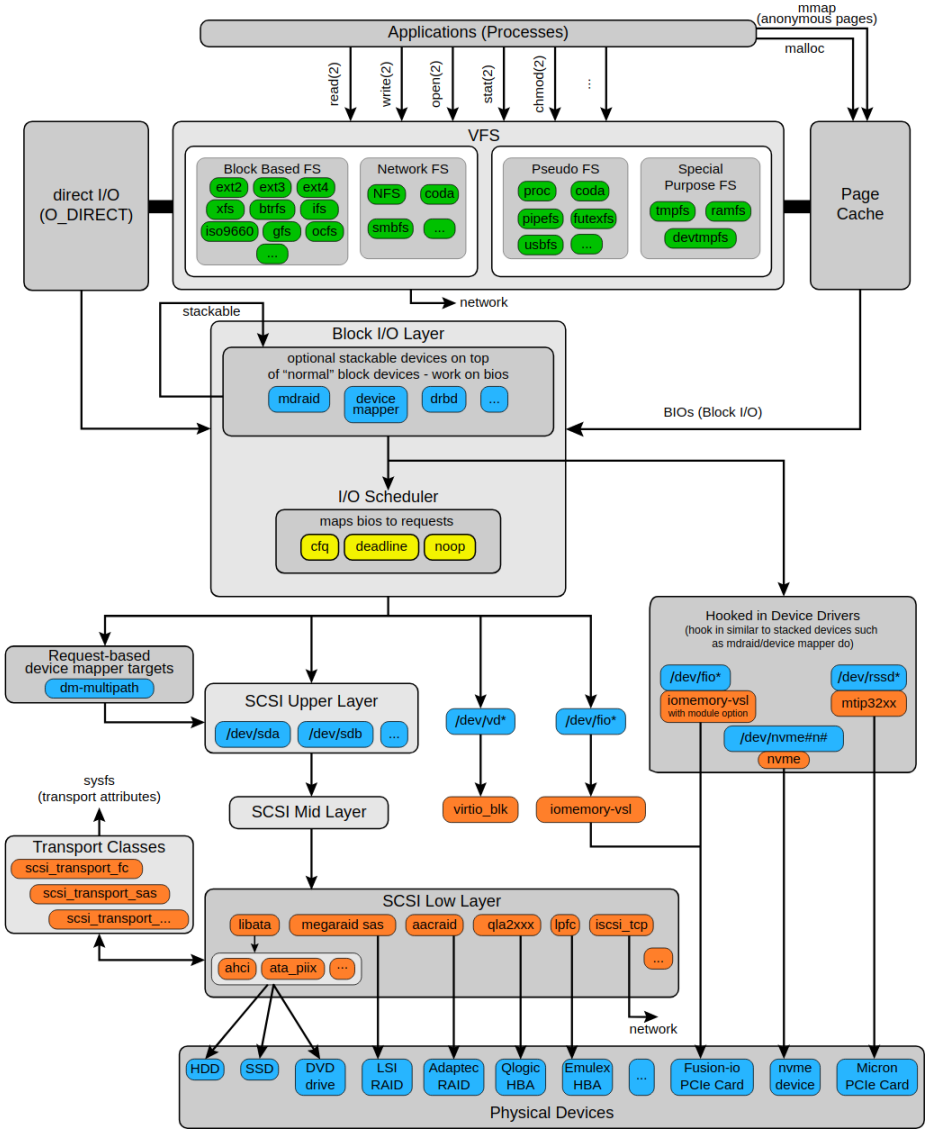

Основные операции с файлами и каталогами

- файлы
  - создание, удаление
  - чтение, запись данных
    - текст
    - бинарные данные
  - чтение, изменение атрибутов
- каталоги
  - создание, удаление
  - чтение содержимого
  - чтение, изменение атрибутов

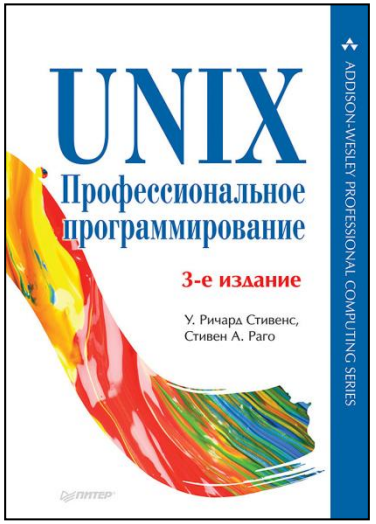

Главы 3 – 5

Ввод-вывод с помощью системных вызовов

- основные системные вызовы: `open()`, `read()`, `write()`, `lseek()`, `close()`
- открытые файлы идентифицируются с помощью дескрипторов (целое число типа int)

```
int fd = open("hello.txt", O_RDONLY);
if (fd < 0) {
        // Ошибка
}
else {
        // OK
        ...
        close(fd);      // дескрипторы необходимо закрывать!
}
```

Что нужно знать про read() и write()

- основные вызовы для чтения/записи данных из/в файлы, сокеты, каналы, ...
- возвращают количество прочитанных/записанных байтов или -1

```
#include <unistd.h>

ssize_t read(int fd, void *buf, size_t count);
ssize_t write(int fd, void *buf, size_t count);
```

Ввод-вывод с помощью стандартной библиотеки C

- `fopen(), fgets(), fputs(), fread(), fwrite(), fseek(), fclose(), ...`
- открытые файлы идентифицируются с помощью указателей на структуру FILE

```
FILE *fp = fopen("hello.txt", "r");
if (!fp) {
        // Ошибка
}
else {
        // OK
        ...
        fclose(fp);     // Указатели на файлы необходимо закрывать!
}
```

Буферизация при вводе-выводе

- буферизация в ядре – page cache, гранулярность – блок ФС (фактически – страница)
- буферизация в библиотеке C, гранулярность – настраиваемая с помощью setvbuf()

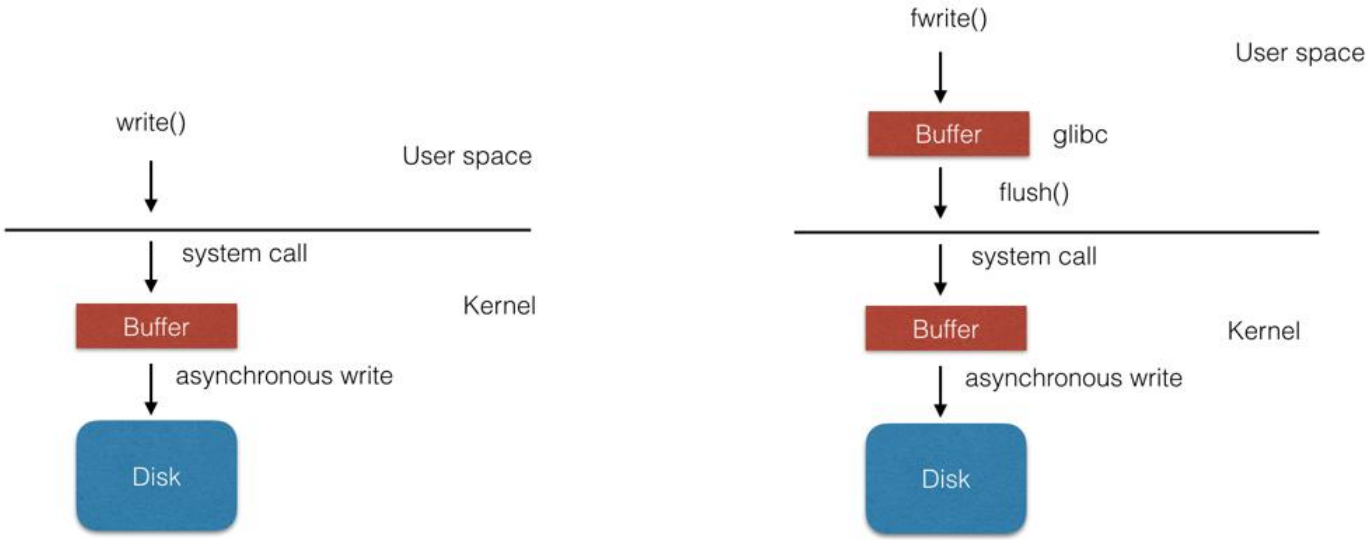

Буферизация потоков

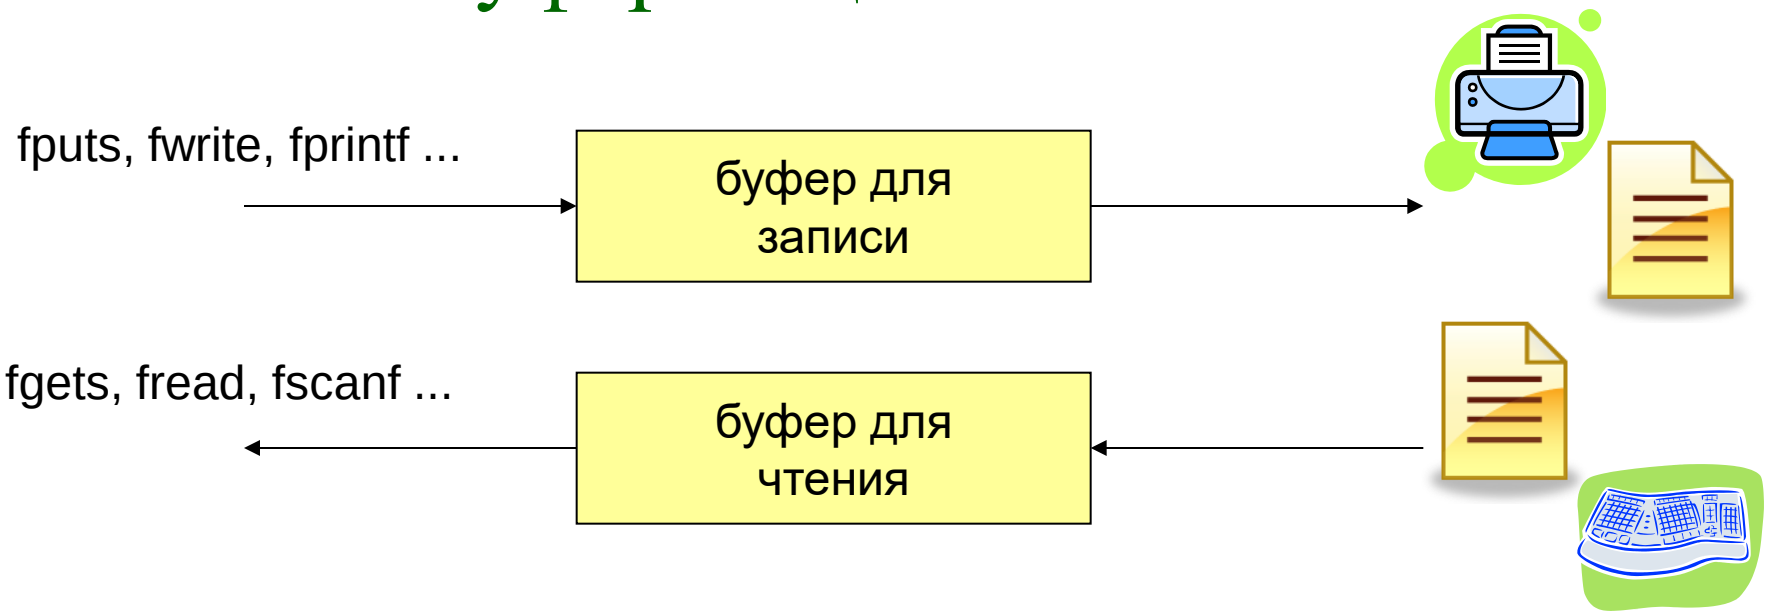

увеличение скорости операций чтения/записи за счет сокращения количества обращений к устройству (диску, консоли и т.д.)

Управление буферизацией

```
int setvbuf(FILE *stream, char *buffer,
            int mode, size_t size)

...
char *buffer = (char*)malloc(1024*1024);
setvbuf(f, buffer, _IOFBF, 1024*1024);

...
setvbuf(f, NULL, _IONBF, 0);
```

Пара слов о типах файлов

текстовые (plain text)

бинарные (binary)

по формату (типу данных, которые хранятся в файле):

- исполняемые (программы)
- картинки
- видео
- аудио
- документы
- псевдофайлы (специальные файлы)
- …

Бинарные файлы

binary – файлы, содержащие любые данные (и текстовые, и не текстовые)

– байт (число без знака в диапазоне 0 .. 255)

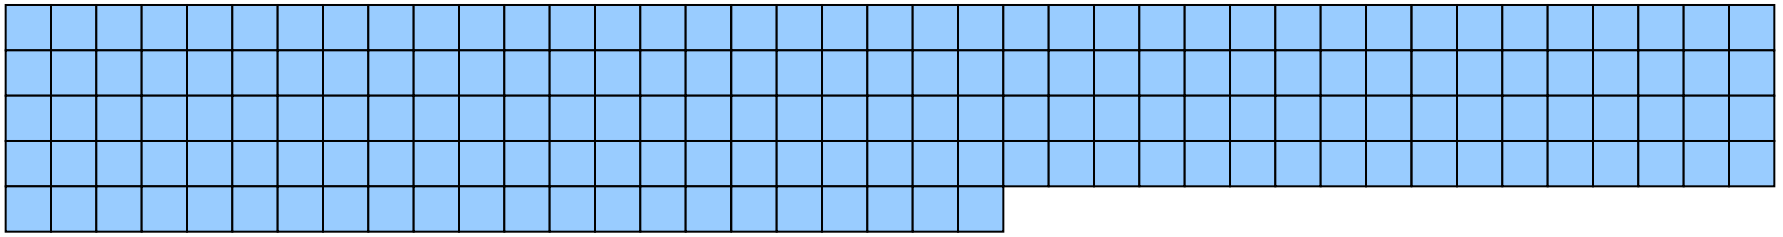

http://ru.wikipedia.org/wiki/Двоичный_файл

Текстовые файлы

plain text – файлы в восьмибитной кодировке, содержащие только текстовые данные

– текстовый символ (буква, цифра, знак препинания, пробел, табуляция …)

– управляющий символ - признак перевода строки

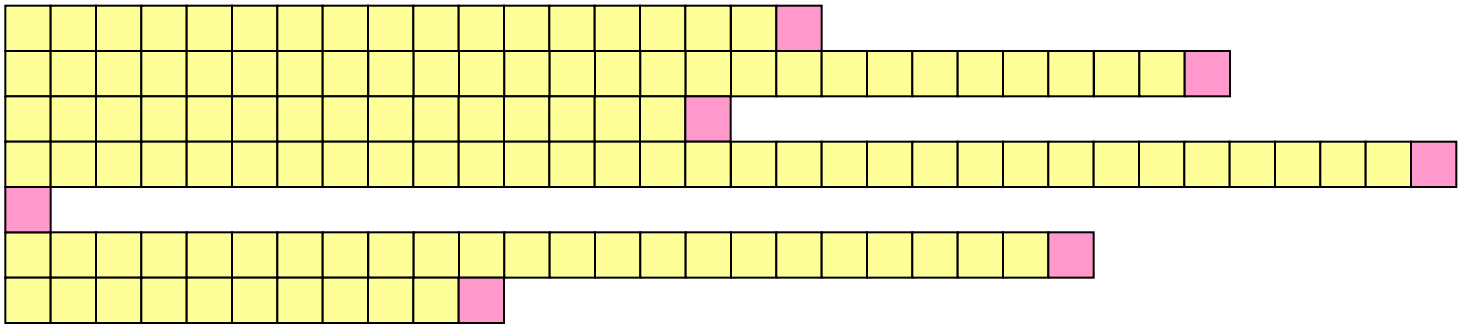

http://ru.wikipedia.org/wiki/Plain_text

Признак перехода на новую строку

Windows

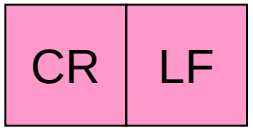

UNIX, Linux

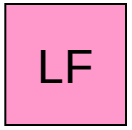

CR = Carriage Return (возврат каретки)

ASCII code, 13 (0xD) **'\r'**

LF = Line Feed (перевод строки)

ASCII code 10 (0xA), **'\n'**

Традиционная ошибка

- посимвольное чтение из файла с помощью fgetch()
- не настолько неэффективно, как может показаться, но в случаях, когда быстродействие важно, следует использовать mmap()

Построчное чтение файла

- можно использовать fgets()
  - если строки длинные, то можно не прочитать строку целиком – не катастрофа, но может создать неудобство
  - какого размера требуется буфер?
- проще пользоваться getline()
  - тем более, что теперь она входит в POSIX.1

Текущий (рабочий) каталог

- файл программы размещается в некотором каталоге
  - для программ, установленных в системе есть некоторый набор более-менее стандартных каталогов
    - подробнее в FHS (https://ru.wikipedia.org/wiki/FHS)
- каждому процессу ОС определяет текущий рабочий каталог
  - можно получить с помощью getcwd()

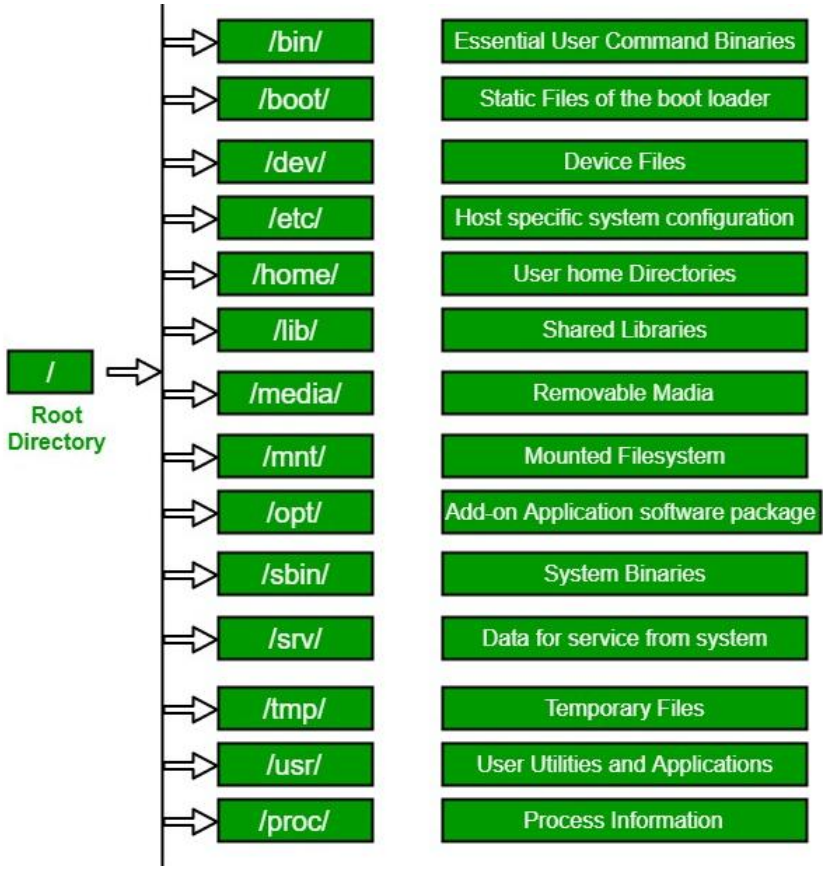

Обход дерева каталогов

- "сложный" вариант
  - рекурсивный обход с помощью chdir()/readdir()
- "простой" вариант
  - использование функции ntfw()

Многозадачность и процессы

Термины

- Параллелизм (parallelism)
- Конкурентность (concurrency)
- Многозадачность (multitasking)
- Многопроцессность (multiprocessing)
- Многопоточность (multithreading)
- Асинхронная обработка (anynchronous processing)

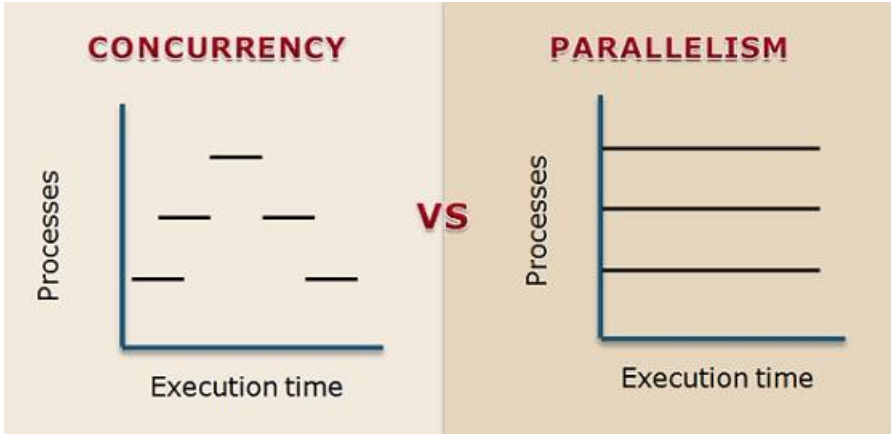

Многозадачность

Linux – многопользовательская многозадачная ОС общего назначения

- задача (task)
- **программа (program)**
- **процесс (process)**
- поток (thread)
- задание (job)
- сессия (session)
- группы
  - процессов (process groups)
  - потоков (thread groups)

Процессы

Процесс – загруженная в память программа, единица учета системных ресурсов в ОС

- состояния процесса
- разделение памяти и адресное пространство процесса
  - MMU и ОС отображают страницы виртуального адресного пространства на страницы оперативной (физической) памяти
- изоляция процессов
  - ограничение и учет ресурсов: chroot, namespaces, cgroups

Состояния процесса в ОС Linux

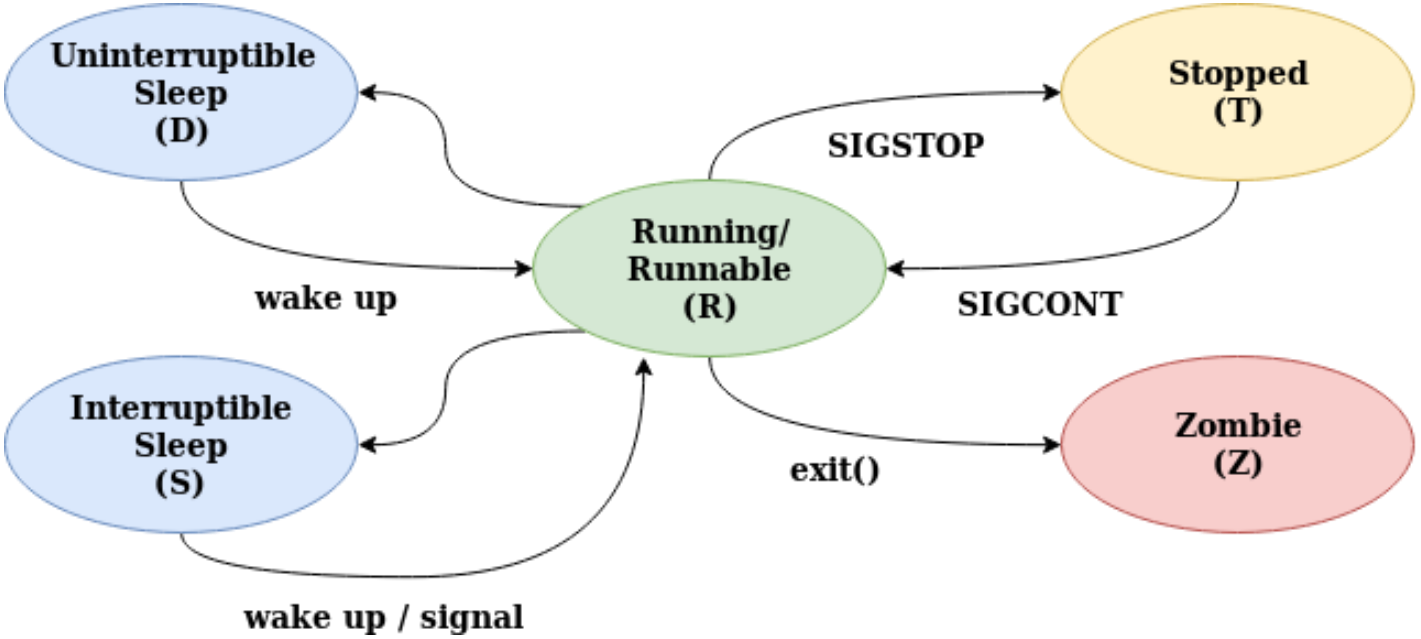

Квант времени выполнения процесса

Квант времени выполнения (*time slice, time quantum*) – время, в течение которого процесс может исполняться на ядре процессора, прежде, чем диспетчер ОС инициирует переключение контекста

- в большинстве ОС – переменная величина, определяется динамически планировщиком процессов (обычно от десятков до сотен миллисекунд)
- в Linux при использовании алгоритма Completely Fair Scheduler квант по умолчанию составляет от 0.75 мс до 6 мс (от sched_min_granularity_ns до sched_latency_ns)

Контекст процесса и переключение контекста

Переключение контекста (*context switch*) – совокупность действий, которые необходимо выполнить ядру ОС для того, чтобы перестать выполнять код одного процесса и начать выполнять код другого процесса

- сохранение/восстановление регистров
- сброс TLB (?) и конвеера процессорного ядра
- как следствие: увеличение промахов кэшей всех уровней

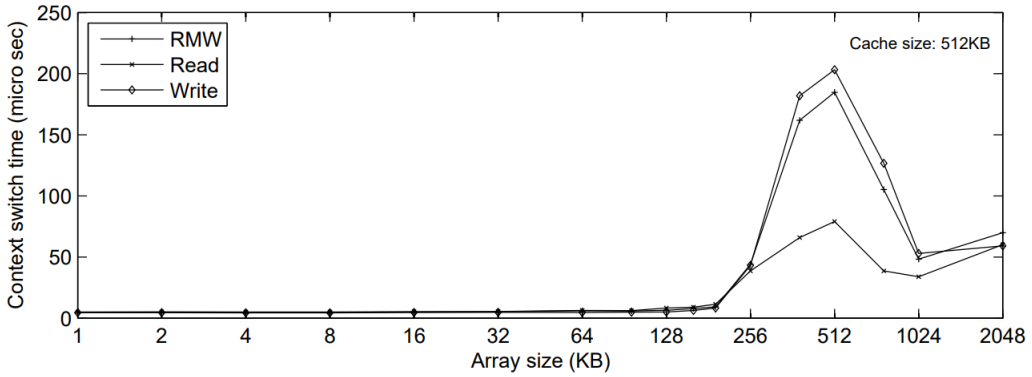

Figure 1: The effect of data size on the cost of the context switch

https://www.usenix.org/legacy/events/expcs07/papers/2-li.pdf

Процессы и потоки

- Несколько упрощая ситуацию, можно считать, что процесс – это некоторый "контейнер" для ресурсов и внутри каждого процесса выполняется как минимум один поток (thread)
  - эта упрощенная модель не соответствует действительности как минимум для Linux, как максимум – для многих POSIX-совместимых ОС

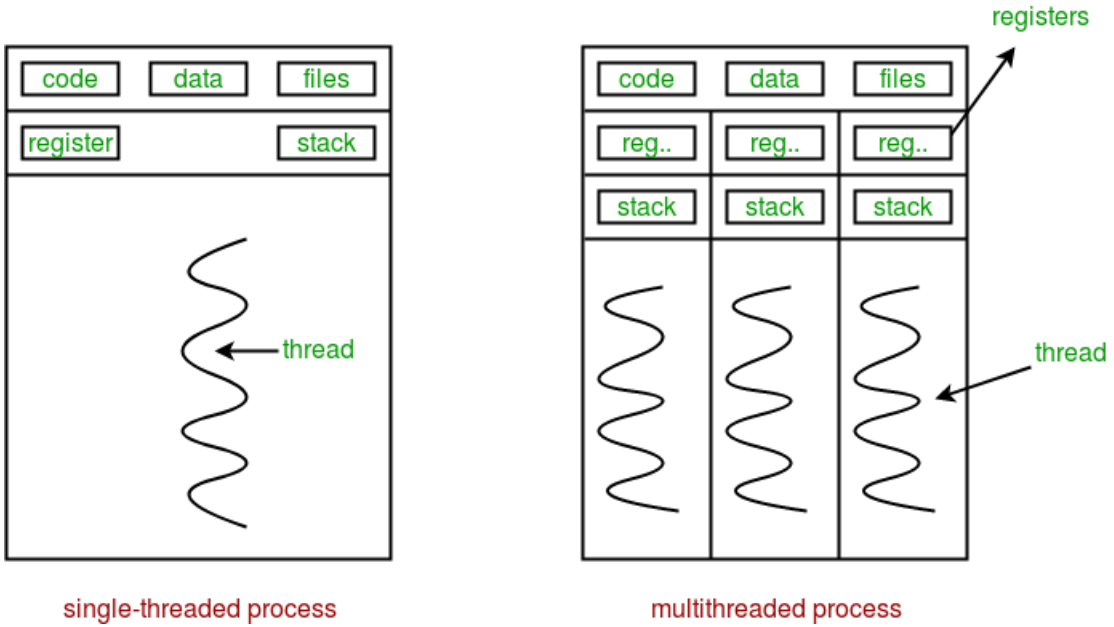

Управление процессами

Вопросы, связанные с управлением процессами:

- создание процессов
- завершение процессов
  - "принудительное" и "добровольное"
- получение информации о результате выполнения процесса
- сигналы
- взаимодействие между процессами
  - каналы
  - сокеты и другие IPC (разделяемая память, очереди сообщений, семафоры)
- организация групп процессов, сессий и другие элементы управления заданиями
  - создание процессов-демонов

Создание нового процесса

Системный вызов fork()

```
#include <sys/types.h>
#include <unistd.h>

pid_t fork(void);
```

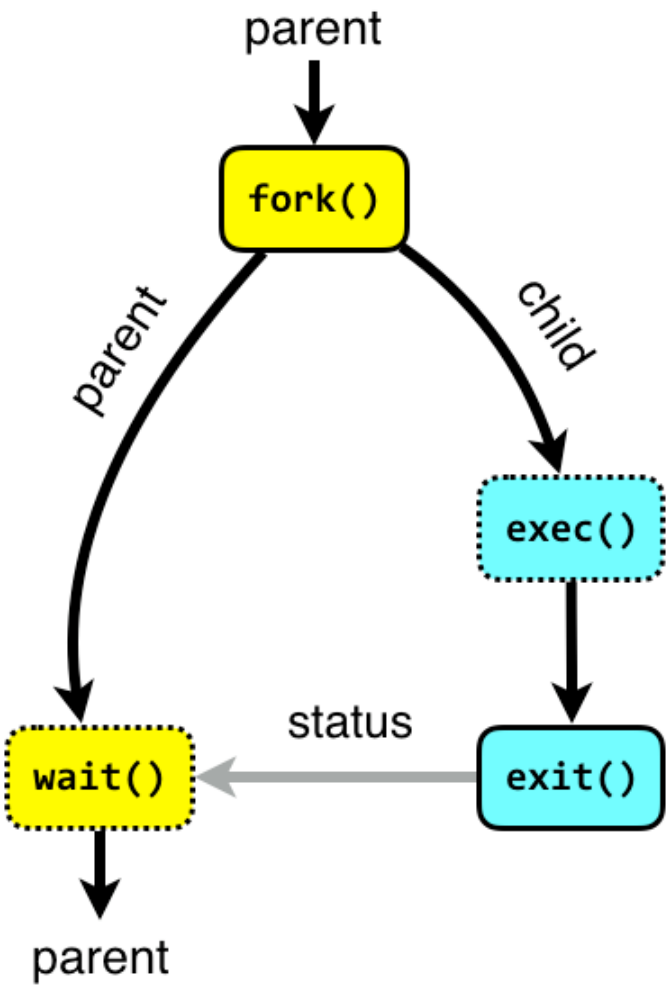

Создание нового процесса

```
pid_t child;
if ((child = fork()) < 0) {
  // ошибка
}
else if (child == 0) {
  // внутри нового процесса
}
else {
  // внутри родительского процесса
}
```

Что наследует порожденный процесс

- окружение
- открытые дескрипторы
- umask
- текущий рабочий каталог и корневой каталог
- приоритет
- управляющий терминал
- маску сигналов, диспозицию и обработчики сигналов
- права (реальный и эффективный UID и GID)

Что у родителя и потомка разного?

- ID процесса (PID) и ID родительского процесса (PPID)
- PID потомка гарантированно отличается от ID любой существующей группы процессов
- статистика использования системных ресурсов
- если в родительском процессе ожидали доставки сигналы, в потомке они сбрасываются
- блокировки файлов, установленные в родительском процессе, не дублируются в потомке

Идентификация процесса

- ID процесса и родительского процесса можно получить с помощью системных вызовов getpid() и getppid()
- Если родительский процесс завершается раньше дочернего, то новым родителем становится процесс с ID == 1

```
#include <sys/types.h>
#include <unistd.h>

pid_t getpid(void);
pid_t getppid(void);
```

Запуск новой программы внутри процесса

С помощью семейства системных вызовов exec():

```
#include <unistd.h>

int execv(const char *path, char *const argv[]);
int execvp(const char *file, char *const argv[]);
int execvpe(const char *file, char *const argv[],
                        char *const envp[]);
```

- возврат из exec() возможен только в случае ошибки
- ID процесса не меняется
- в argv[0] может быть передана произвольная строка

Какие атрибуты наследуются процессом при вызове exec

- дескрипторы открытых файлов и каталогов, кроме тех, которые имели флаг O_CLOEXEC
- umask
- рабочий и корневой каталоги
- приоритет
- ID процесса, родительского процесса и группы процесса
- маска сигналов, диспозиция и обработчики сигналов, а также ожидающие доставки сигналы!
- права (действительные и эффективные UID/GID)
- блокировки файлов
- статистика использования ресурсов

Запуск новых программ

- Идиома "fork and exec"
  - fork не блокирует родительский процесс, используется copy-on-write
  - vfork() – запуск с блокировкой родителя

```
#include <sys/types.h>
#include <unistd.h>

pid_t fork(void);
```

Завершение процесса

```
#include <stdlib.h>

void exit(int status);

void _Exit(int status);

#include <unistd.h>

void _exit(int status);
```

Регистрация обработчиков завершения

atexit() и on_exit()

```
#include <stdlib.h>

int atexit(void (*function)(void));
int on_exit(void (*function)(int, void*),
  void *arg);
```

Когда что использовать

- в обычных ситуациях exit()
  - если в порожденном процессе вызов exec() завершается неудачей, тогда использовать _exit(), чтобы избежать повторных сбросов буферов файлов, открытых в родительском процессе
- набор кодов завершения (8 bit)
  - EXIT_SUCESS, EXIT_FAILURE
  - либо определить свой набор кодов

При запуске из скрипта оболочки

```
#!/bin/bash

some_program -x -y -z in.txt out.txt
if [[ $? != 0 ]]
then
  # ошибка!
fi
```

Получение статуса завершения процесса

- после завершения процесса ядро сохраняет статус завершения и сведения об использовании ресурсов процессом
- процесс, который завершился, но статус которого не был получен родителем, становится *зомби*

Ожидание завершения

- Системный вызов wait() ожидает завершения любого порожденного процесса
- возвращает -1, если порожденных процессов не осталось

```
#include <sys/types.h>
#include <sys/wait.h>

pid_t wait(int *wstatus);
```

Ожидание завершения

- Системный вызов waitpid() ожидает завершения любого или заданного порожденного процесса

```
#include <sys/types.h>
#include <sys/wait.h>

pid_t waitpid(pid_t pid, int *wstatus,
    int options);
```

`pid < -1` – ждать завершения процесса с ID группы pid
`pid = -1` – ждать завершения любого порожденного процесса
`pid = 0` – ждать завершения любого процесса с ID группы родителя
`pid > 0` – ждать завершения процесса с заданным pid

- опция WNOHANG позволяет делать неблокирующую проверку

Получение информации о ресурсах

- Системные вызовы wait3() и wait4() позволяют получить информацию о ресурсах, которые потребил дочерний процесс:

```
#include <sys/types.h>
#include <sys/time.h>
#include <sys/resource.h>
#include <sys/wait.h>

pid_t wait3(int *wstatus, int options,
                    struct rusage *rusage);

pid_t wait4(pid_t pid, int *wstatus, int options,
                    struct rusage *rusage);
```

Дополнительные способы запустить процесс в Linux

- system

```
#include <stdlib.h>
int system(const char *command);
```

- popen

```
#include <stdio.h>
FILE *popen(const char *command, const char *type);
int pclose(FILE *stream);
```

- posix_spawn

```
#include <spawn.h>
int posix_spawn(pid_t *pid, const char *path,
    const posix_spawn_file_actions_t *file_actions,
    const posix_spawnattr_t *attrp,
    char *const argv[], char *const envp[]);
```

Правда о запуске процессов в Linux

- Процессы и потоки в Linux запускаются с помощью системного вызова clone()

```
#define _GNU_SOURCE
#include <sched.h>

int clone(int (*fn)(void *), void *stack,
  int flags, void *arg, ...);
```

Приоритет процесса

- Процесс может установить относительный приоритет с помощью системного вызова nice

```
#include <unistd.h>

int nice(int inc);
```

Трассировка программ

Трассировщики

- Трассировщики – инструментальные программы, позволяющие отслеживать последовательность вызовов функций в программах
- Для Linux актуальны
  - `ltrace`
    - использует ptrace()
  - `strace`
    - использует ptrace()
  - `stap` (System Tap)
    - использует eBPF bytecode

Трассировка библиотечных вызовов

- Для трассировки вызовов из динамических библиотек используется ltrace
  - не работает с PIE, при компиляции требуется отключить:

```
$ gcc -no-pie -o test test.c
```

Трассировка системных вызовов

- Для трассировки системных вызовов используется strace
  - можно подключиться к уже работающему процессу с помощью -p <pid>

Задание на дом

- читать
  - Стивенс, Раго. UNIX. Профессиональное программирование
    - главы 3 – 5, 7, 8
  - Лав. Linux: Системное программирование
    - главы 2, 3, 4
  - man 2 open, close, read, write
  - man ltrace
  - man strace
  - man fork
  - man clone (бегло просмотреть)